

潜在的ディリクレ配分法と大規模言語モデルを利用した単一データに対する新しいタグづけ手法の検討

竹本 智博[†] 福原 義久[†]

[†] 武蔵野大学 データサイエンス学部データサイエンス学科 福原研究室

〒135-8181 東京都江東区有明3丁目3-3

E-mail: [†]ts2322039@stu.musashino-u.ac.jp, ^{††}yoshihisa.fukuhara@ds.musashino-u.ac.jp

あらまし 本研究では、潜在的ディリクレ配分法を用いたトピックモデルと大規模言語モデルを利用した単一データに対する新しいタグづけ方法を提案する。既存の研究ではトピックモデルより得られたトピックをそのまま単一データのタグとする方法はあるが、この手法ではコーパスに対する単一のデータの特徴をよく表しているとは言いにくい。そこで本研究ではタグづけの際に大規模言語モデルを用い、その単一データの特徴を表したタグを生成させることを目標とする。これにより、トピックモデルが持つ、複数のトピックを持つという利点を生かし、同じタグを持つ別のトピックを抽出したり、適切なタグづけによって検索条件をさらに絞ることなどが可能になる。

キーワード 大規模言語モデル、コーパス構築

1 はじめに

総務省の統計によれば、2000年代以降、インターネットの爆発的な普及とともに、オンラインで利用・閲覧可能な文書の数はい指数関数的に増加した。[1] デジタルデータとして保存・解析が容易な特性から、これらの文書は様々な分析手法や応用サービスに利用されてきた。近年では大規模言語モデルを中心とした生成AIが急速に進化し、より多様で大規模な文書資源を取り扱うことが一般化している。その一方で、あまりに大量の文書が氾濫する環境下では、文書の適切な整理・分類・検索が困難となりつつある。

本研究では、こうした文書整理の一手段として、自動タグづけシステムに着目した。タグを付与することにより、文書の検索や推薦が容易になり、またユーザが文書内容を一目で把握できるようになるなど、多くの利点がある。ただし、土井らは、LDAなどの既存のトピックモデルのみに基づく手法だけでは、単一の文書の特徴を十分に捉えきれない場合があるとしている。[2] そこで本研究では、トピックモデルの代表的手法である潜在的ディリクレ配分法(LDA)と、大規模言語モデルを組み合わせ、単一の文書に対し、より適切かつ情報量のあるタグを自動生成する新たな手法を提案する。

1.1 本稿における言葉の定義

1.1.1 文書

本稿では意図を持って集められた複数の文書の集合を「文書群」、その群を構成している単一の文書を「単一文書」と表現する。

1.1.2 タグ

本稿で扱う「タグ」とは、以下の二要件を満たす単一文書のメタデータであるとする。

1. 付与された単一文書の内容を端的に表現するものである。

2. 文書群において、単一文書の関連性を明示するものである。

1.2 既存手法の問題点

Pandyaらは自動的にタグを付与する際に、ドキュメントに対するタグが過剰に生成される「over-tagging」と、タグが一切付与されていない、またはごくわずかなタグしか提供しない「under-tagging」の二つを問題として挙げている。[3] これらはいずれもタグが本来果たすべき「文書同士の関連性を表す」という点を阻害し、結果として検索や推薦システムにおける精度低下や、ユーザの混乱を招く原因となる。

over-taggingとなった場合には、ユーザはどのタグを検索に使えばよいかわからなくなり、一方でunder-taggingとなった場合には、必要な文書に辿り着くための軸がほとんど存在しない状態となる。このように、タグづけが適切でないということは、タグの定義2である関連性を明示するというものが機能していないこととほぼ同義であるので、防がねばならない。

また草野は、LLMにおける自動タグ付けを検討する際に、特に工夫をしなければタグが爆発的に増えてしまうことを問題に挙げ、結果的に文書群に付与されるタグの総数が過多になるとしている。[4] これも、同じタグを持つ単一文書が少ないということであり、関連性を明示するという点で防がねばならない。

総じて、LLMの発展により、単一文書に対する固有のタグ付けに関しては精度が高いが、関連性を明示するという視点に立った時にそれを制御する手法はまだ貧弱である。

2 関連研究

2.1 潜在的ディリクレ配分法

Latent Dirichlet Allocation (LDA) は、Bleiら[5]により提案された文書の潜在トピック推定手法である。基本仮定は以下の通り：

- 文書は複数トピックの混合である。

- 各トピックは関連単語の確率分布で表される。
- 各単語は、まずトピックが決定され、その後そのトピックの分布に従って生成される。

ディリクレ分布を用いた生成過程の逆推定により、文書集合内の潜在トピックを単語の確率分布として取得する。

2.2 Method for Customizable Automated Tagging

Pandya ら [3] は、over-tagging と under-tagging を抑制しながら文書に自動でタグ付与する手法を提案している。本手法は以下の手順で構成される：

- キーワード抽出：IBM Watson NLU により、信頼スコア 0.5 以上のキーワードを抽出する。
- トピックモデリング：LDA でキーワードを集約し、冗長性の少ないタグ候補を生成する。
- タグ付け：キーワードとタグ候補を照合し、最適なタグを割り当てる。

これは文書全体のトピック構造を踏まえたタグ付与が特徴である。

3 提案手法

3.1 狙い

本研究で提案する手法は、潜在的ディリクレ配分法 (LDA) が持つトピック構造の自動抽出機能と、大規模言語モデルが得意とする柔軟な文章解析・生成機能を組み合わせ、個々の文書の特徴に合ったタグを生成するものである。

以下の観点から、これら 2 つの技術を組み合わせるメリットがある。

1. **LDA による複数トピック情報の活用**：LDA は文書を一つのトピックに固定せず、複数のトピックの混合比率として捉える。これにより、文書が持つ多面性をタグ化に反映しやすくなる。
2. **大規模言語モデルによる柔軟なテキスト生成**：LDA から得られる単語分布はあくまで単語の羅列であり、そのままではユーザの検索や理解に直結しづらい。一方、大規模言語モデルは単語分布のような生情報を踏まえて、文脈を考慮したラベル (タグ) を生成できる。これにより、より自然言語的な表現でのタグづけが可能となる。

こうした仕組みにより、本研究の手法は単一データごとに適切な粒度のタグを生み出し、なおかつ文書群全体の背景 (トピック構造) を考慮した整理が期待できる。

3.2 流れ

以下に、本研究が提案するタグづけ手法の概要を示す。

1. **トピックモデルの学習**：文書群を用意し、McCab などの形態素解析ツールを使ってコーパスを作成する。これを用いて、LDA によるトピックモデルを学習する。ハイパーパラメータ (トピック数やディリクレ事前分布のパラメータなど) はグリッドサーチを行い、ある程度妥当な値を決定する。
2. **トピックごとのタグ数の決定**：全ての単一文書をトピック

モデルに入力し、単一文書ごとのトピックの重みを取得する。トピックごとに重みを平均し、文書群に対するトピックの重みを計算する。事前に与えられていた文書群に対する総タグ数に、文書群に対するトピックの重みを掛けることでトピックごとに幾つのタグを生成するのかを決定する。

3. **プロンプトの作成とタグの新規作成**：トピックごとのタグ数をもとに、トピックとの関連度が高い単一文書をタグ数分取得し、それをもとに、LLM にタグを生成させるためのプロンプトを作成、LLM に入力し、新たなタグを取得する。以下はプロンプトの一例。

本文
(単一文書の本文)
要望
以上を示した本文を、この後に示す単語群の視点から解析し、それに合うタグをある程度ほかの文章にも適合できそうな程度に汎化させつつ、一つだけ生成してください。
単語群
作品, 編集, 連載, 監督, ビデオ, 記事, 上映, レポート
出力形式
生成したタグのみを示すこと。先頭のハッシュ記号は不要です。かならず一つのタグのみを出力すること。「/」などで区切ってはいけません。
例：キャンプ用品

4. **既存のタグの割り当て**：トピックとの関連度が低く、先の手順で選ばなかった文書のトピックについて、そのトピックで先に生成されたタグを明示し、その中から適切なタグを LLM に決めさせる。
5. **タグの抽出**：タグの新規作成と、それらを踏まえた割り当てをもとに、最終的に単一文書につけられたタグを決定する。

単一文書 α タグをつける際のイメージを図 1 に示す。




図 1 手法の流れのイメージ

4 結果

4.1 実際の例

データセットとして livedoor のニュースコーパスを用い

た. [6] これは国内ニュースを中心としたウェブ記事を集めたコーパスであり、カテゴリも多様かつ記事数も比較的多い. 実験では、解析用に計 864 のニュース記事を用いて LDA の学習を行った.

4.1.1 単一文章例とタグ生成結果

次に示すニュース本文例に対して、提案手法を用いてタグづけを行った.

この実験では、Google 社の Gemini2.0Flash を用いた.

忘年会シーズンは要注意！ Facebook 上にある 76 %は恥ずかしい写真だった【話題】 Facebook の魅力の一つが、写真の公開や共有だ。では、どのような写真が多くアップされているのだろうか？ イギリスでの調査では「酔っぱらっているときの写真」がタグ付けされた写真のうち 76 %をしめるということがわかった。飲み会やパーティなどで写真を撮る機会が増えるからということも原因だろうが、56 %が職場の人に見られたくない写真が公開されている、と答え、8 %が見られると深刻な問題になってしまうと答えている。

うっかりハメを外してしまった瞬間が Facebook で公開されているとなると、職場の同僚や上司と Facebook でつながっている人にとっては重要な問題になってしまう。

自分は気をつけていても、友人が名前にタグをつけて公開してしまうことも十分に考えられるので、事前に「Facebook に上げるときは先に声をかけてほしい」など伝えておくことも必要かもしれない。

忘年会が増えるこのシーズン、楽しい飲み会が悲しい結果を招かないように注意していきたい。

Facebook 写真の 76 %が酒に酔っているときの写真—英国

■関連記事・これでさみしくない！クリスマスの「おひとりさま」を生温かくもてなしてくれるニコニコ本社【クリスマス】・2012 年はどうなる？タイの大洪水の影響が長引きパソコン出荷台数が減少か【話題】・たくさん押されないとクドカンが眠れない！ NHK の「眠いいね！」ボタンが気になる【話題】・ほぼ 2 人に 1 人はスマホ持ち！アメリカでのスマホ普及が広がる【話題】・マーク・ザッカーバーグが Facebook に訴えられる！？【話題】

この文書に対し、提案手法を用いてタグ付けを行い、以下のような出力を得た.

注意喚起, SNS 利用, ソーシャルメディアの注意点, 写真投稿への配慮

4.2 主観評価

表 1 タグづけ結果に対する被験者評価

文書	反映度の平均	具体度の平均
1	8.00	7.69
2	7.91	7.36
3	7.45	6.55

4.2.1 実験設定

提案手法の評価を行うために、864 あるニュースコーパスから、ランダムで 3 本の記事を選び、それに対し提案手法でタグづけを行った. 続いて、以下に示す観点で 12 名にアンケートを取った.

それぞれの項目に関して、1 から 10 段階での評価を求めている.

- 反映度:単一文書に対してどの程度タグが情報をカバーしているか
- 具体度:タグの粒度は適切か

4.2.2 結果

表 1 に文書ごとの評価結果を示す.

4.3 客観評価

4.3.1 実験手法

客観評価を行うために、以下の手法を行った.

- ヒストグラムによるタグ数の寡多の可視化
- 同一の単一文書につけられたタグのコサイン類似度の計算
- リトリバル品質の算出

4.3.2 タグの寡多

生成されたタグ数の分布を図 2 により確認する. これを見ると、タグ数 7 を最頻値とし、正規分布に近い分布をしていることがわかる.

4.3.3 コサイン類似度の計算

各単一文書に対し生成されたタグ同士のベクトル間のコサイン類似度を計算する. 結果を図 3 に示す. ここから、多くが 0.5 前後に分布していることがわかる.

4.3.4 リトリバル品質の算出

リトリバル品質 (retrieval quality) を計算し、その結果を図 4 に示す.

リトリバル品質とは各文書に付与されたタグ同士の一致度を計算し、最も一致度の高い上位 5 件の平均を求めることで、付与されたタグが文書群の中でどの程度相互的に関連しているかを測る指標である.

ヒストグラムより、0.3 前後に値が分布しているのがわかる.




図 2 タグ数の分布




図 3 タグのコサイン類似度の分布




図 4 タグのリトリバル品質の分布

5 考 察

5.1 主観評価について

主観評価においては被験者より高いスコアを得られた。

文書 3 について比較的评价が低いのは、美容系雑貨の記事であるのに対し、タグが「美容家電」、関連話題記事、美容家電、メンズ美容、生活家電」というものである。

コサイン類似度については、その記事では「0.60」と高めの値を出しており、タグ同士の内容が重複していることと、逆にそれ以外の情報が含まれていないことに起因すると考えられる。

よって、コサイン類似度は特に文書 1 と 2 がそれぞれ 0.54 と 0.53 であることを考えると、ある程度高すぎでは主観評価が下がるということが分かった。

5.2 客観評価について

Pandya らの研究では一つの文書に対し 1 から 72 個のタグが付与される可能性があり、under-tagging を「3 個以下」、over-tagging を「21 個以上」と定義している。本実験では学習済みの LDA が最適としたトピック数が 17 であったため、文書ごとに多くても 17 種類のトピックが割り当てられる。そのため、この設定下では over-tagging は起きなかった。一方、under-tagging に該当する文書は 1 割程度存在し、短文やノイズの多い文書においてタグ数が少なくなる傾向が認められた。

また、コサイン類似度については、先の通り、0.6 を超えるものは高すぎると考えられる。実験結果では 0.5 の階級が最頻値であり、単一文書に付与されたタグの粒度としてはある程度

良いものが得られたと考えられる。

リトリバル品質は、値が大きいかほど同じタグを持った単一文書が多いということであり、これを見ると、この実験では値は小さい。また確認してみたところ、タグ数は 3000 になるようにしていたが、実際には 1416 しか生成されていない。これはタグを LLM により新規作成したものの、既存のタグと全く同じタグが生成されたということであり、これがリトリバル品質の値を小さくしたと考えられる。今回行った主観評価ではリトリバル品質の是非を判定できないので、今後はそれも測れるようにしなければならない。また、リトリバル品質についてはどの程度新規のタグを生成させられるかという点により強く左右されるため、プロンプトの変更や、事前に与える総タグ数の大きさによって分布を変えることが可能である。この実験では「汎化させたタグ」という指定をしたので、同じ文言のタグが多く生成されてしまい、リトリバルの値が小さくなった可能性が高い。

よって、主観評価と組み合わせ、適切なプロンプトや総タグ数を決定できるようにしていきたい。

5.3 展 望

今後の課題としては、(1) 単一文書に付与されたタグのコサイン類似度をどのように変えるべきか、(2) 学習時に取り込まれるノイズ語をどのように取り除くかが挙げられる。

また、現在のものでは基本的な「名詞、動詞、形容詞」のみを抽出しているが、事前にテキストクリーニングやドメイン知識を活用した除外リストを設けることで、より精度の高いトピック推定が行える可能性がある。

6 おわりに

本研究で示した手法は、ニュース記事やブログ記事など、ある程度長さのある文章に対しては特に有効性が期待できる。将来的には、カスタマーサポートのチャットや、動画のコメントなど、より多様な形式のテキストへ適用することで、高度な検索・推薦システムを構築するための一助となると考えられる。

文 献

- [1] 総務省, “インターネットの登場・普及とコミュニケーションの変化,” Available at: <https://www.soumu.go.jp/johotsusintokei/whitepaper/ja/r01/html/nd111120.html>, Accessed: January 8, 2025.
- [2] 土井智暉, 磯沼大, 谷中暉, “大規模言語モデルによる少数かつ短文の文書に対するトピックモデリング,” 言語処理学会 第 30 回年次大会, 2024.
- [3] M. R. Pandya, J. Reyes, and B. Vanderheyden, “Method for Customizable Automated Tagging,” arXiv preprint arXiv:2005.00042, 2020.
- [4] 草野元紀, “大規模言語モデルを用いたタグ付けによるデータの品質向上,” 言語処理学会 第 30 回年次大会, 2024.
- [5] D. M. Blei, A. Y. Ng, and M. I. Jordan, “Latent Dirichlet Allocation,” Journal of Machine Learning Research, Vol. 3, pp. 993–1022, 2003.
- [6] LiveDoor, “livedoor ニュースコーパス,” Available at: <http://www.rondhuit.com/download.html#ldcc>, Accessed: January 8, 2025.