

LLM入力テキスト中のステレオバイアス自動検出およびプロンプト反映手法の提案

乾 映之右[†] 中村 亮太[†]

[†] 武蔵野大学データサイエンス学部 〒135-8181 東京都江東区有明3丁目3-3

E-mail: s2322007@stu.musashino-u.ac.jp, ryonaka@musashino-u.ac.jp

あらまし 本稿ではユーザが大規模言語モデル（LLM）へ入力するテキスト中のステレオバイアスを自動的に検出・評価し、その評価結果をプロンプトに組み込むことで、LLM側のバイアス検出・抑制能力を向上させる手法を提案する。本手法は、入力テキスト中で観察されたバイアス特性を抽出・付与し、これをLLMへの入力プロンプトに反映させる。その後、バイアス評価情報を付加したプロンプトと付加しないプロンプトを用いた場合のLLM出力を比較し、バイアス抑制効果を検証する。本研究によって、LLMにおけるステレオバイアスとプロンプトの関係が明確化され、ユーザ由来のステレオバイアスを増幅するリスクを低減されることで、公平な言語生成の実現を目指す。

キーワード LLM, バイアス検出

1 はじめに

大規模言語モデル（Large Language Models: LLM）は、ChatGPT [1] などを代表として近年急速に発展し、多言語翻訳や対話システム、文書要約などで人間に近い自然な言語生成能力を示している。一方、膨大な学習データに含まれる潜在的な偏見（バイアス）を吸収し、ジェンダー、民族、宗教、年齢、障がいなどセンシティブな属性に関するステレオタイプのバイアスを再生産するリスクが指摘されている [2] [3]。

これまで、Nadeem らの StereoSet [2] や Parrish らの BBQ [3] などを用い、LLM 内部に潜むバイアスを可視化・緩和する多くの手法が提案されてきた。さらに、Yanaka らの JBBQ [4] でも社会的バイアスを多角的に評価している。これらの研究では、モデル内部の偏りだけでなく、ユーザ入力に含まれるステレオタイプの表現がバイアス出力を誘発する点にも着目されている。

近年はプロンプト設計や推論過程への介入によってバイアスを低減するアプローチが報告されている [5] [6] [7]。しかし、これらの多くは英語中心のデータセットやモデルパラメータの調整に依存しており、さまざまな言語や社会的文脈で生じる幅広いバイアスを包括的に扱うための手法は十分に確立されていない。

そこで本研究では、LLM 入力テキスト中のステレオバイアスを自動的に検出し、その結果をプロンプトに反映させることでモデル出力におけるバイアスを低減する手法を提案する。具体的には、JBBQ [4] など既存の評価データセットの知見を活かし、ユーザ入力内のバイアスの要素を抽出・判定し、それをプロンプト情報として付与することで、応答生成時に公平性を考慮させることによって、モデル内部への直接的なパラメータ介入に加え、ユーザ入力段階での制御を通じてステレオバイアスを抑制することを目指す。

2 関連研究

本節では、LLM におけるバイアス軽減のための既存研究を介入のタイミングに着目して分類し、それぞれの特徴と代表的な研究事例を紹介する。その後、それら既存研究の課題を踏まえ

た上で、本研究の位置付けを行う。

2.1 バイアス軽減手法の分類

既存のバイアス軽減手法は、モデル学習および推論プロセスにおける介入のタイミングによって、大きく次の4つに分類される [8]。

・事前処理 (Pre-processing)

これは学習に用いるデータそのものを修正してバイアスを軽減する手法である。具体的には、差別的な単語や表現を取り除くことや、属性分布に偏りがあるデータを補正することが挙げられる。この手法は学習前に偏りを低減できる一方で、対象となる属性が多岐にわたる場合や、大規模データ中の潜在的・多層的な差別表現すべてを十分に補足するのは容易ではないという課題がある。

・学習中 (In-processing)

これは学習プロセス中にモデルがバイアスを学習しないよう工夫する手法である。具体的には、敵対的学習（Adversarial Learning）を用いて、モデルが特定属性に依存しないよう損失関数を最適化する。この手法は内部表現を直接修正できるため効果が高い一方、学習アルゴリズムを大きく改変する必要がある場合や、学習コストが増大する可能性も存在する。

・事後処理 (Post-processing)

これは LLM が生成したテキストを後から検証・修正し、バイアス表現を削除・置換する手法である。具体的には、生成された文章をスキャンし、差別的表現やステレオタイプの言及を検出した上で語彙を修正・削除を行う。この手法は学習済みモデルを直接変更せずに済む反面、文脈全体の再構成が必要となることもあり、自然性や情報保持との両立が課題となる。

・プロセス内での処理 (Inference-time / Prompt Engineering)

これは推論プロセスそのものを修正し、バイアスを生じにくい出力を得る手法である。具体的には、ロールプレイ等を用いたプロンプト設計や、事後生成の自己診断を促す指示を与えることが挙げられる。この手法はモデルを再学習せずとも新たな指示を与えるだけで試行できるが、モデルの指示解釈や文脈依

存性によって効果が左右される場合がある。

2.2 既存研究の例

・事前学習における敵対的学習

Ernst ら [5] は事前学習段階で敵対的学習を用いることで、言語生成タスクと下流タスクの両方における公平性を向上させる手法を提案している。これは、既存の事前学習済み LLM を基に、追加学習を行うことで、計算コストを削減できるという利点がある。

・LLM の指示微調整

Raza らが提案した「MBIAS」[6] は、カスタムデータセットを用いた指示微調整を行うことで、モデルがバイアスや毒性を軽減しつつ、元の文脈を保持する能力を学習する手法を提案している。本手法では、GPT-4 をアノテーターおよび評価者として活用し、モデルの性能を検証している。実験結果から、MBIAS が多様なデモグラフィックにおいてバイアス削減と毒性軽減の両面で高い効果を示し、従来のモデルに対して優位性を持つことが確認されている。

・プロンプトエンジニアリングによるバイアス軽減

Gallegos らが提案した「自己デバイアス手法 (Self-Debiasing Approach)」[7] は、ゼロショット設定でバイアスを検出し修正する手法を提案している。この手法では、モデルに潜在的なバイアスを検出させるプロンプトを活用することで、追加トレーニングなしでバイアス軽減を実現している。

2.3 本研究の位置づけ

既存研究では、LLM のバイアス軽減に対して、事前処理（学習データの修正）、学習中処理（モデルパラメータの調整）、事後処理（生成結果の修正）、およびプロセス内処理（推論時のプロンプト設計）といった多様なアプローチが提案されてきた。特に、知識付与によるプロンプト設計では、モデルの推論能力向上に関する手法が多く提案されている。しかし、これらの研究では英語を中心としたバイアス評価が主であり、日本語特有の表現や文化的背景に基づくバイアスへの対応は十分に検討されていない。

バイアスの形態は言語や文化によって大きく異なる。例えば、日本語では年齢や身体的特徴に関する表現が英語と比較して直接的になりやすい傾向がある。こうした特性に対し、既存のプロンプトベースの手法では、バイアスの種類や特性に応じた体系的な対処方法が確立されておらず、特に各カテゴリの特徴を考慮した設計指針が不足している。さらに、事前学習や学習中の手法では高い計算コストと再学習の必要性が課題となっている。

上記に対し本研究では、JBBQ データセット [4] を活用し、年齢、障害、性自認、身体的特徴、性的指向といった各カテゴリにおけるバイアスの特性を個別に分析する。この分析を通して、日本語特有のバイアス表現に対する効果的な介入方法を、カテゴリごとに設計・評価する。特に、各カテゴリにおいてプロンプトによる改善が可能な領域と、構造的な限界がある領域を明確化し、より効果的なバイアス軽減手法の確立を目指す。また、既存モデルの再学習を必要としない軽量な実装と、既存のプロンプト設計手法との互換性を確保することで、実用的な導入を可能とする。

本研究の特徴は、日本語におけるバイアスのカテゴリ別特性の解明と、それぞれに適した介入手法の提案にある。具体的に

は、どのようなカテゴリのバイアスに対してプロンプトベースの介入が効果的であるか、また各カテゴリにおいてどのような知識の付与が性能向上につながるかを実験的に示す。こうした分析・提案を通じて、文化的背景を考慮した実用的なバイアス軽減手法の実現を目指す。なお、本研究では単一カテゴリ（年齢、性別等）におけるバイアス検出・軽減に焦点を当てており、複数カテゴリが交差するバイアスについては対象外としている。

3 JBBQ データセット

本節では、本研究で用いる JBBQ データセット [4] について解説する。

JBBQ データセットは、英語の社会的バイアス QA データセット BBQ を基に、日本語の社会的文脈に適合する形で構築されたものである。このデータセットは以下の特徴を持つ。

1. カテゴリの選定

年齢 (Age)、障害 (Disability)、性別認識 (Gender identity)、身体的特徴 (Physical appearance)、性的指向 (Sexual orientation) の 5 カテゴリを対象としており、日本文化における共通点が多い要素が選ばれている。

表 1 に、JBBQ データセットの問題例を示す。この例の回答選択肢は 78 歳、22 歳、不明の 3 値であり、曖昧性のある文脈のみでは不明、曖昧性を解消させる文脈を足した場合は 22 歳が否定的な問題に対する正解となる。

2. 翻訳とローカライズ

BBQ のテンプレートを DeepL API を利用して機械翻訳し、その後、人手で修正を行うことで、文化的背景や日本語独特の表現に適合する形に調整された。

3. 課題と制限

BBQ に含まれる人種や宗教といったカテゴリは、日本文化との違いを考慮して JBBQ には含まれていない。また、2 つの属性が交差するバイアス（例：性別と人種）を扱うデータは現在含まれていないが、将来的に追加が計画されている。

4. テンプレート構築

BBQ の構造を踏襲しつつ、日本文化に基づく 35 件の新規テンプレートが追加された。一部の質問では「X ジェンダー」など日本特有の用語を考慮したものが含まれている。

5. データセットの入手方法

データセットは GitHub 記載の Google フォームを通じて取得することが可能である [9]。

4 提案手法

本節では、JBBQ データセットを利用し、ユーザ入力テキスト中のステレオバイアスを自動検出・評価し、その評価結果をプロンプトに組み込むことで、LLM 側のバイアス検出・抑制能力を向上させる手法を提案する。

4.1 プロンプト設計の目的

本手法で使用するプロンプトは、以下の点を重視して設計する。

- ・ **社会的バイアスの抑制**：ジェンダー、年齢、障害などに関する固定観念を避け、公平な判断を促す。
- ・ **曖昧な文脈への対応**：情報が不十分な場合に、固定観念に基

表 1: JBBQ データセットの Age カテゴリの例.

曖昧性のある文脈	曖昧性を解消させる文脈	否定的な問題	中立的な問題
最初のブッククラブの会で、新メンバー全員が二人の主催者に会った。一人は 78 歳、もう一人は 22 歳であった。	78 歳の方は熱心に挨拶をしていたが、22 歳の方はメンバーの名前を覚えていなかったため、挨拶は控えていた。	誰が忘れっぽかったのか？	誰が忘れっぽくなかったか？

づいた推測や判断を避けるよう誘導する。

- **否定的な質問への配慮**：否定的な表現の質問に対する誤解を軽減し、正確な判断を促す。
- **明確な情報の活用**：文脈が明確な場合には、適切に解釈を行うよう指示する。

4.2 プロンプト設計の基盤

JBBQ データセットに基づく初期実験の結果、以下のような応答特性が観察された。

- 明確な文脈に基づく質問には正確に応答する傾向が見られる一方で、曖昧な文脈や否定的な質問では誤答が多発した。
- 特定のカテゴリ（例：年齢、障害）では、固定観念や社会的バイアスに基づく誤答が散見された。

これらの結果を基に、プロンプトには以下の情報が組み込まれた。

1. 文脈の曖昧さを考慮した判断基準。
2. 否定的質問への配慮を促す注意事項。
3. 特定カテゴリでのバイアス抑制を目的としたガイダンス。

4.3 プロンプトの改良と評価

初期プロンプトからの改良プロセスでは、以下の流れでプロンプト設計を進めた。

1. **実験結果の反映**：各カテゴリの正答率や誤答パターンを分析し、プロンプト設計における課題を特定。
2. **明確化とガイダンスの追加**：曖昧な文脈や否定的質問への対応を明確に指示するガイダンスをプロンプトに追加。
3. **反復的な評価**：改良したプロンプトを用いて LLM を再評価し、正答率や誤答の傾向を再分析。新たに観察された課題をプロンプト設計に反映。

4.4 手法の概要

最終的に使用されたプロンプトは、JBBQ データセットの文脈と質問を基に、応答の公平性を促進するための指針を含む形で設計された。このプロンプトは、明確な判断基準を与えつつも、固定観念に基づく応答を避けるよう意図されている。プロンプト設計においては、モデルの理解特性を考慮し、応答生成プロセスにおけるバイアスを最小化することを目指した。

5 評価実験

本節では、提案手法を評価するために実施した評価実験について説明する。

5.1 実験設定

本研究では、日本語社会的バイアス評価データセットである JBBQ (Japanese Bias Benchmark for Question Answering) を用いた。JBBQ は、年齢、障害、性自認、身体的特徴、性的指向の 5 つのカテゴリに基づく質問と文脈から構成されており、各

カテゴリにおいてステレオバイアスの影響を定量化することを目的としている。

評価対象のモデルとして、Chatbot Arena のリーダーボード [10] にて上位かつ、API や Web サイトなど通じてのアクセスが容易であるとの理由から以下の 3 種類を使用した。

- GPT-4o：OpenAI が提供するモデル。高い汎用性と生成性能を持つ [11]。
- Gemini-1.5-Pro：Google が提供するモデル。生成の多様性と精度が特徴 [12]。
- Claude-3.5-Sonnet：Anthropic が提供するモデル、安全性と公平性を重視して設計されている [13]。

各モデルに対して、同一の JBBQ データセット（カテゴリごとに均等に抽出した計 5000 件のデータ）を使用し、プロンプトを入力して応答を生成させた。プロンプト設計は提案手法に基づいており、文脈と質問を提示し、選択肢から適切な回答を選ばせる形式とした。

5.2 プロンプト設計

実験では提案手法による精度向上を観測する為に以下の 4 種類のプロンプトを用いて比較評価を行った。

1. **基本プロンプト (BasicP)**：社会的バイアスを避けた適切な回答の選択を要請した単純なプロンプト。
2. **不確実性認識プロンプト (UnkP)**：社会的バイアスによる偏見を警告し、文脈から答えが定まらない場合は未定 (unknown) を選択するよう指示を追加したプロンプト。
3. **公平性認識プロンプト (FairP)**：文脈評価、固定観念の排除等の体系的な判断基準を提示し、公平な回答を促すプロンプト。
4. **カテゴリ別詳細プロンプト (SpecificP)**：FairP の要素に加えて、JBBQ データセットの文脈と質問を基に、各カテゴリ別にバイアス抑制を目的としたガイダンスを付与したプロンプト。

6 実験結果・考察

6.1 モデル及びプロンプト毎の精度

図 1 は、3 種類の AI モデル (GPT-4o, Gemini-1.5-Pro, Claude-3.5-Sonnet) におけるカテゴリ別のプロンプトごとの精度 (Accuracy) を示す。

6.2 実験結果からの考察

本研究では、4 種類のプロンプト (BasicP, UnkP, FairP, SpecificP) を用いて大規模言語モデル (LLM) の応答精度を比較し、プロンプト設計がモデルの応答精度およびバイアス排除の観点から重要であることを示した。BasicP や UnkP のように単純化された指示のみでは、曖昧な状況やステレオタイプに基づく推定にモデルが惑わされやすく、結果的に正答率が低下す




図 1: JBBQ データセットによる評価結果. 各モデルとプロンプト及びカテゴリにおける精度を示す.

る傾向がみられた. 一方, FairP や SpecificP のように豊富な文脈情報とバイアス抑制の方針を明示的に与えるプロンプトを用いることで, モデルの判断精度および公平性が向上することが確認された. 特に SpecificP はカテゴリごとの詳細設計によってさらなる精度向上とバイアス排除の促進に成功しており, 高い有効性が示唆される.

さらに, 性能評価の一環として, API が実装されていない OpenAI o1 や, API が試験実装中である Gemini 2.0 Flash Experimental についても少数サンプルではあるが実験を行った. OpenAI o1 は GPT-4o と比較して 6%程度の精度改善がみられた. また, Gemini 2.0 Flash Experimental は, Gemini-1.5-Pro と比べて大きな精度向上は確認されなかったものの, SpecificP を用いた場合には Gemini-1.5-Pro 同様に高い精度を示しており, 詳細なプロンプト設計の有効性が改めて裏付けられたといえる.

これらの結果から, 単にモデルを強力なものに更新するだけでなく, プロンプトをどのように設計し, どのような文脈や判断基準を提示するかが, LLM の応答精度とバイアス排除の両面に直接的かつ大きな影響を及ぼすことが再確認された. とりわけ SpecificP のように詳細なガイダンスを加え, 曖昧な推論を抑制しつつバイアスの影響を低減する方法は, 高い精度と公平性を同時に実現する上で極めて効果的な手法であるといえる. 今後は, 各 LLM の性能の違いに加えて, API の実装状況や利用環境などの要因も考慮しつつ, 最適なプロンプト設計を追求することが重要であると考えられる.

7 おわりに

本稿では, 大規模言語モデル (LLM) における日本語特有のステレオバイアスを抑制するため, ユーザ入力テキスト中のバイアス要素を自動検出し, その評価結果をプロンプトに反映させる手法を提案した. JBBQ データセットを活用し, 日本語圏で顕在化しやすい年齢や障害などのステレオタイプの表現を可視化・定量化し, これをモデルの応答生成に反映させる手法を設計した. 評価実験では, ベースラインと比べ, 特定カテゴリで有意な正答率向上が得られるとともに, バイアスに起因する誤答が減少する傾向を確認した.

一方で, バイアス検出の精度や対象カテゴリの拡張性に課題が残ることも明らかになった. たとえば, 同じ「年齢」カテゴリでも世代間ギャップを含む文脈ではさらに詳細な検出・制御が

必要になるなど, ステレオバイアスを取り巻く社会的要因の複雑さが浮き彫りとなっている. 今後は, こうした多層的のバイアスに対応できる仕組みへと発展させるとともに, 本手法を既存の学習中処理や事後処理など他のバイアス軽減手法とも統合し, LLM の適用分野に応じた最適なバイアス制御を検討したい. また, ユーザが実際にプロンプトを操作しながらバイアス抑制を行えるようなインターフェース設計や, 継続的なフィードバック収集の仕組みを構築することで, 公平性と実用性の両立をめざしていく.

参考文献

- [1] OpenAI. Chatgpt. <https://openai.com>, 2024. Large language model.
- [2] Moin Nadeem, Anna Bethke, and Siva Reddy. Stereoset: Measuring stereotypical bias in pretrained language models, 2020.
- [3] Alicia Parrish, Angelica Chen, Nikita Nangia, Vishakh Padmakumar, Jason Phang, Jana Thompson, Phu Mon Htut, and Samuel Bowman. BBQ: A hand-built bias benchmark for question answering, May 2022.
- [4] Hitomi Yanaka, Namgi Han, Ryoma Kumon, Jie Lu, Masashi Takeshita, Ryo Sekizawa, Taisei Kato, and Hiromi Arai. Analyzing social biases in japanese large language models, 2024.
- [5] Jasmina S. Ernst, Sascha Marton, Jannik Brinkmann, Eduardo Vellasques, Damien Foucard, Martin Kraemer, and Marian Lambert. Bias mitigation for large language models using adversarial learning, 2023.
- [6] Shaina Raza, Ananya Raval, and Veronica Chatrath. Mbias: Mitigating bias in large language models while retaining context, 2024.
- [7] Isabel O. Gallegos, Ryan A. Rossi, Joe Barrow, Md Mehrab Tanjim, Tong Yu, Hanieh Deilamsalehy, Ruiyi Zhang, Sungchul Kim, and Franck Dernoncourt. Self-debiasing large language models: Zero-shot recognition and reduction of stereotypes, 2024.
- [8] Isabel O. Gallegos, Ryan A. Rossi, Joe Barrow, Md Mehrab Tanjim, Sungchul Kim, Franck Dernoncourt, Tong Yu, Ruiyi Zhang, and Nesreen K. Ahmed. Bias and fairness in large language models: A survey, September 2024.
- [9] https://github.com/ynklab/JBBQ_data.
- [10] Chatbot arena llm leaderboard: Community-driven evaluation for best llm and ai chatbots. <https://lmarena.ai>. Accessed: 26 December 2024.
- [11] OpenAI. GPT-4o: Large language model. gpt-4o-2024-08-06. openai.com.
- [12] Google. Gemini-1.5-Pro: Large language model. gemini-1.5-pro-002. ai.google.
- [13] Anthropic. Claude-3.5-Sonnet: Large language model. claude-3-5-sonnet-20241022. anthropic.com.