

潜在的ディリクレ配分法と大規模言語モデルを利用した 単一データに対する新しいタグづけ手法の検討

竹本 智博 福原 義久
武蔵野大学 データサイエンス学部 データサイエンス学科

背景・動機

近年の情報化の急速な進展に伴い、取り扱われるデータの量は飛躍的に増大している[1]。こうした膨大なデータを適切に整理・管理する手法の一つとして、文書に対する自動タグ付けが注目されている。本研究では、自動タグ付けに焦点を当て、その効率性と精度を向上させる新たな手法を提案する。

定義

本稿ではタグを以下のように定義する。


- 単一文書のメタデータである。
- 付与された単一文書の内容を端的に表現するものである。
- 文書群において、単一文書の関連性を明示するものである。

関連研究[2]

潜在的ディリクレ配分法(LDA)とはトピックモデルの手法の一つであり、モデルに文書群を学習させた後、単一文書を入力すると、文書を構成していると考えられるトピックを複数個、“単語の確率分布という形”で出力する。

提案手法

単一文書αに対するタグ付けの流れ



この手法では統計的手法であるLDAを用いることでタグ数の無作為な増大を抑制し、単一文書の相互の関連性を把握しやすくする。また、トピックモデルを用いることで、文書を複数の視点からタグ付けできる。それとともに、LLMを用いることで、その柔軟な生成能力を用いることで、与えられた単一文書の内容に即したタグを生成できるようにする。

実験

livedoorニュースのデータセットを用いた。データ数は864点。アンケートを用い、主観評価をしてもらうとともに、調べる単一文書につけられたタグ同士の類似度を測るコサイン類似度と、タグ同士の相関性を測るリトリバル品質を用いた。

結果・考察

それぞれの結果を以下に示す。

表 1 タグづけ結果に対する被験者評価

文書	反映度の平均	具体度の平均
1	8.00	7.69
2	7.91	7.36
3	7.45	6.55





表1を見ると、1~10段階の評価を行ったが、比較的高い値を示している。

図2より、タグ数の寡多に関してはタグの定義2を損なうほど、タグ数が過少/過多のものはみられない。[3]

また、図4を見ると、リトリバル品質が全体的に小さい。これは同じタグを持つ単一文書同士が少ないということである。実験ではプロンプトにて「汎化させたタグ」を生成するようにしていたが、タグの定義3に基づくのであれば、プロンプトなどを調整し、さらに同じタグを付与されるようにすべきである。

総括

この研究では、タグの「端的に内容を表す」、「文書の相関を示す」という定義をある程度満たす手法を提案した。展望として、アンケートに相関性を測れるものを入れることで、リトリバル品質がどの程度が人にとって適切かを測れるようにしたい。

参考

- [1]総務省, ``インターネットの登場・普及とコミュニケーションの変化," Available at: <https://www.soumu.go.jp/johotsusintokei/whitepaper/ja/r01/html/nd111120.html>, Accessed: January 8, 2025.
- [2]D. M. Blei, A. Y. Ng, and M. I. Jordan, ``Latent Dirichlet Allocation,"Journal of Machine Learning Research, Vol. 3, pp. 993--1022, 2003.
- [3]M. R. Pandya, J. Reyes, and B. Vanderheyden, ``Method for Customizable Automated Tagging," arXiv preprint arXiv:2005.00042, 2020.